


Kompleksowa Analiza EDA i Segmentacja Rynku E-Commerce (Olist)

1. Cel i Zakres Projektu

Projekt przedstawia proces end-to-end analizy eksploracyjnej (EDA) brazylijskiego rynku e-commerce na podstawie rzeczywistych, anonimowych danych platformy **Olist** (ok. 100 tys. zamówień z lat 2016–2018).

Schemat Relacji Bazy Danych (ERD)

Poniższy diagram przedstawia architekturę połączeń i klucze relacyjne pomiędzy tabelami w silniku DuckDB. Pomaga on zrozumieć strukturę bazy przed przystąpieniem do budowania zapytań SQL:



Podejście Technologiczne

W projekcie wykorzystano nowoczesny stos technologiczny: **Python** jako środowisko uruchomieniowe oraz **DuckDB** jako osadzony, wysoce wydajny silnik SQL działający w pamięci (In-Memory). Wszystkie transformacje, czyszczenie oraz agregacje danych zostały wykonane za pomocą **czystego SQL**, co pozwala na błyskawiczne przetwarzanie dużych zbiorów danych bez nadmiernego obciążania pamięci RAM przez tradycyjne biblioteki.

Krok 1 & 2: Konfiguracja Środowiska, Rejestracja Danych i Testy Integralności

W tej sekcji inicjalizujemy bazę danych oraz mapujemy pliki CSV bezpośrednio jako widoki w DuckDB. Stosujemy regułę **DRY (Don't Repeat Yourself)** przy użyciu pętli słownika. Przeprowadzamy również testy jakości danych (unikalność kluczy głównych oraz brak rekordów osieroconych).

✓ Sukces: Wszystkie pliki CSV zostały pomyślnie podpięte jako widoki SQL.

```
--- 1. WOLUMEN DANYCH W TABELACH ---
Tabela 'customers': 99,441 wierszy
Tabela 'geolocation': 1,000,163 wierszy
Tabela 'order_items': 112,650 wierszy
Tabela 'order_payments': 103,886 wierszy
Tabela 'order_reviews': 99,224 wierszy
Tabela 'orders': 99,441 wierszy
Tabela 'products': 32,951 wierszy
Tabela 'sellers': 3,095 wierszy
Tabela 'translation': 71 wierszy

--- 2. WERYFIKACJA UNIKALNOŚCI KLUCZA GŁÓWNEGO (orders) ---
  total_rows  unique_keys  duplicate_count
0          99441          99441              0

--- 3. TEST INTEGRALNOŚCI REFERENCYJNEJ (Orders -> Customers) ---
Liczba zamówień bez przypisanego klienta (sierot): 0
```

Krok 3: Czyszczenie Danych i Zaawansowany Feature Engineering

W tym kroku budujemy warstwę danych oczyszczonych (`v_cleaned_*`). Wykorzystujemy rzutowanie typów (`::TIMESTAMP`), mapujemy portugalskie nazwy kategorii na język angielski za pomocą zapytań relacyjnych oraz stosujemy funkcję `COALESCE` , aby bezpiecznie obsłużyć wartości `NULL` . Dodatkowo wprowadzamy dedykowane metryki biznesowe (czas dostawy, flaga opóźnienia).

Uruchamianie procesów transformacji danych i budowania widoków analitycznych...

✓ Sukces: Widoki transformacyjne zostały poprawnie utworzone w bazie danych.

--- ANALIZA ZALEŻNOŚCI BRAKU DATY DOSTAWY OD STATUSU ZAMÓWIENIA ---


	order_status	total_orders	missing_delivery_date
0	delivered	96478	8
1	shipped	1107	1107
2	canceled	625	619
3	unavailable	609	609
4	invoiced	314	314
5	processing	301	301
6	created	5	5
7	approved	2	2

Krok 4: Analiza Właściwa (EDA) – Hipotezy Biznesowe i Wizualizacje

Przechodzimy do testowania kluczowych hipotez biznesowych. Łączymy wyniki zaawansowanych agregacji SQL bezpośrednio z bibliotekami wizualizacyjnymi (`Seaborn` i `Matplotlib`).


Hipoteza 1: Trend Przychodów i Wolumenu Zamówień w Czasie

Badamy stabilność wzrostu platformy i identyfikujemy piki sprzedażowe (sezonowość, m.in. Black Friday).



Hipoteza 2: Analiza Logistyczna i Wąskie Gardła w Dostawach

Weryfikujemy, które stany w Brazylii charakteryzują się najwyższym współczynnikiem opóźnień przesyłek w stosunku do deklarowanej daty estymowanej.



Hipoteza 3: Wpływ Jakości Logistyki na Satysfakcję Klienta


Sprawdzamy, jak niedotrzymanie obietnicy logistycznej (opóźnienie) wpływa na oceny wystawiane przez klientów w ankietach (`review_score`).

--- WPŁYW OPÓŹNIEŃ LOGISTYCZNYCH NA SATYSFAKCJĘ (0 = na czas, 1 = opóźnione) ---

is_delayed	avg_review_score	total_reviews
0	4.29	88653
1	2.57	7708

Krok 5: Zaawansowana Analityka – Segmentacja Klientów RFM

Budujemy kompletny model segmentacyjny oparty o trzy wymiary: Recency, Frequency oraz Monetary. Wykorzystujemy zaawansowane funkcje okna `NTILE()` oraz logikę warunkową `CASE WHEN` bezpośrednio w silniku SQL.



6. Podsumowanie Biznesowe i Rekomendacje (Executive Summary)

Przeprowadzona analiza eksploracyjna (EDA) oraz zaawansowana segmentacja RFM na danych platformy **Olist** pozwalają na sformułowanie kluczowych wniosków oraz strategicznych rekomendacji dla rozwoju biznesu.

1. Główne Wnioski z Analizy Danych (Insights)

- **Stabilny wzrost z wyraźną sezonowością:** Platforma wykazuje stały trend wzrostowy przychodów i wolumenu zamówień w latach 2017–2018. Kluczowym punktem sprzedaży w każdym roku jest **Black Friday** (listopad), generujący gwałtowne piki przychodowe, na które logistyka musi być przygotowana z dużym wyprzedzeniem.
- **Wąskie gardła logistyczne:** Analiza geograficzna ujawniła znaczne dysproporcje w czasie dostaw. Niektóre stany w Brazylii (szczególnie te oddalone od centrum gospodarczego, jak np. północne regiony) charakteryzują się niepokojąco wysokim odsetkiem zamówień opóźnionych w stosunku do daty estymowanej.
- **Logistyka bezpośrednim motorem satysfakcji:** Dane jednoznacznie potwierdzają hipotezę, że opóźnienie dostawy drastycznie obniża oceny konsumenckie. Średnia ocena (`review_score`) dla zamówień dostarczonych na czas jest bliska ideału (ok. 4.2-4.5), podczas gdy zamówienia opóźnione skutkują tąpnięciem satysfakcji i drastycznym wzrostem ocen negatywnych (1-2 gwiazdki).

2. Strategia Działań dla Segmentów RFM

W oparciu o dystrybucję klientów w modelu RFM, rekomenduje się wdrożenie zróżnicowanych działań marketingowo-operacyjnych:

Segment klientów	Charakterystyka	Rekomendowana Akcja Biznesowa
Champions (Czempioni)	Kupują bardzo często, niedawno i wydają najwięcej.	Program ambasadorski: Nagradzaj ich ekskluzywnym, wcześniejszym dostępem do nowych produktów. Nie potrzebują agresywnych rabatów cenowych – doceniają status i jakość obsługi.
Loyal Customers (Lojalni)	Regularnie powracający klienci o dobrej wartości.	Programy lojalnościowe: Oferuj spersonalizowane rekomendacje produktowe (Upselling/Cross-selling) oraz darmową dostawę przy przekroczeniu określonego progu koszyka.
Recent Customers (Nowi)	Złożyli zamówienie niedawno, ale to ich pierwszy zakup.	Proces Onboardingu: Wyślij automatyczną sekwencję powitalną (e-mail) z podziękowaniem, instrukcją korzystania z platformy oraz kuponem zniżkowym na <i>drugie</i> zamówienie, aby natychmiast budować nawyk powrotu.
At Risk / Big Spenders (Zagrożeni)	Dawniej zostawiali duże kwoty, ale dawno nic nie kupili.	Kampanie Reaktywacyjne (Win-back): Spersonalizowany kontakt e-mail/SMS typu ' <i>Tęsknimy za Tobą</i> '. Zaoferuj dedykowany, atrakcyjny rabat na kategorie produktów, które przeglądali lub kupowali w przeszłości.
Hibernating / Lost (Uśpieni)	Niska częstotliwość, małe kwoty, brak aktywności od dłuższego czasu.	Automatyzacja niskokosztowa: Nie inwestuj budżetu w drogie kampanie reklamowe (Paid Ads). Ogranicz się do masowych, zautomatyzowanych newsletterów informujących o wielkich wyprzedażach (np. przed Black Friday).

Następne Kroki (Future Work)

Dla dalszego rozwoju projektu warto rozważyć wdrożenie modeli uczenia maszynowego (Machine Learning), takich jak **K-Means Clustering** w celu nienadzorowanej, wielowymiarowej segmentacji klientów oraz modeli predykcyjnych do prognozowania rezygnacji klientów (**Churn Prediction**).

6. Podsumowanie Biznesowe i Rekomendacje (Executive Summary)

Przeprowadzona analiza eksploracyjna (EDA) oraz zaawansowana segmentacja RFM na danych platformy **Olist** pozwalają na sformułowanie kluczowych wniosków oraz strategicznych rekomendacji dla rozwoju biznesu.

1. Główne Wnioski z Analizy Danych (Insights)

- **Stabilny wzrost z wyraźną sezonowością:** Platforma wykazuje stały trend wzrostowy przychodów i wolumenu zamówień w latach 2017–2018. Kluczowym punktem sprzedaży w każdym roku jest **Black Friday** (listopad), generujący gwałtowne piki przychodowe, na które logistyka musi być przygotowana z dużym wyprzedzeniem.
- **Wąskie gardła logistyczne:** Analiza geograficzna ujawniła znaczne dysproporcje w czasie dostaw. Niektóre stany w Brazylii (szczególnie te oddalone od centrum gospodarczego, jak np. północne regiony) charakteryzują się niepokojąco wysokim odsetkiem zamówień opóźnionych w stosunku do daty estymowanej.
- **Logistyka bezpośrednim motorem satysfakcji:** Dane jednoznacznie potwierdzają hipotezę, że opóźnienie dostawy drastycznie obniża oceny konsumenckie. Średnia ocena (`review_score`) dla zamówień dostarczonych na czas jest bliska ideału (ok. 4.2-4.5), podczas gdy zamówienia opóźnione skutkują tąpnięciem satysfakcji i drastycznym wzrostem ocen negatywnych (1-2 gwiazdki).

2. Strategia Działań dla Segmentów RFM

W oparciu o dystrybucję klientów w modelu RFM, rekomenduje się wdrożenie zróżnicowanych działań marketingowo-operacyjnych:

Segment klientów	Charakterystyka	Rekomendowana Akcja Biznesowa
Champions (Czempioni)	Kupują bardzo często, niedawno i wydają najwięcej.	Program ambasadorski: Nagradzaj ich ekskluzywnym, wcześniejszym dostępem do nowych produktów. Nie potrzebują agresywnych rabatów cenowych – doceniają status i jakość obsługi.
Loyal Customers (Lojalni)	Regularnie powracający klienci o dobrej wartości.	Programy lojalnościowe: Oferuj spersonalizowane rekomendacje produktowe (Upselling/Cross-selling) oraz darmową dostawę przy przekroczeniu określonego progu koszyka.

Segment klientów	Charakterystyka	Rekomendowana Akcja Biznesowa
Recent Customers (Nowi)	Złożyli zamówienie niedawno, ale to ich pierwszy zakup.	Proces Onboardingu: Wyślij automatyczną sekwencję powitalną (e-mail) z podziękowaniem, instrukcją korzystania z platformy oraz kuponem zniżkowym na <i>drugie</i> zamówienie, aby natychmiast budować nawyk powrotu.
At Risk / Big Spenders (Zagrożeni)	Dawniej zostawiali duże kwoty, ale dawno nic nie kupili.	Kampanie Reaktywacyjne (Win-back): Spersonalizowany kontakt e-mail/SMS typu ' <i>Tęsknimy za Tobą</i> '. Zaoferuj dedykowany, atrakcyjny rabat na kategorii produktów, które przeglądali lub kupowali w przeszłości.
Hibernating / Lost (Uśpieni)	Niska częstotliwość, małe kwoty, brak aktywności od dłuższego czasu.	Automatyzacja niskokosztowa: Nie inwestuj budżetu w drogie kampanie reklamowe (Paid Ads). Ogranicz się do masowych, zautomatyzowanych newsletterów informujących o wielkich wyprzedażach (np. przed Black Friday).

Następne Kroki (Future Work)

Dla dalszego rozwoju projektu warto rozważyć wdrożenie modeli uczenia maszynowego (Machine Learning), takich jak **K-Means Clustering** w celu nienadzorowanej, wielowymiarowej segmentacji klientów oraz modeli predykcyjnych do prognozowania rezygnacji klientów (**Churn Prediction**).